Correction de l'examen

Partie 1 : Quiz – Compréhension des fondamentaux (5 points)

1. **Quelle est la différence entre l'entraînement d'un LLM et son fine-tuning ?**
   - L'entraînement d'un LLM consiste à former le modèle à partir de zéro en utilisant un large corpus de données textuelles pour apprendre des motifs linguistiques généraux.
   - Le fine-tuning, en revanche, consiste à adapter un modèle pré-entraîné à un domaine spécifique en le réentraînant avec un sous-ensemble de données pertinentes.
2. **Pourquoi le fine-tuning d'un LLM est-il parfois préférable à l'utilisation d'un modèle pré-entraîné sans modification ?**
   - Le fine-tuning permet d'adapter le modèle à un cas d'utilisation spécifique, en améliorant la pertinence et la précision des réponses dans un domaine donné.
   - Un modèle pré-entraîné générique peut donner des réponses moins précises ou biaisées dans un contexte spécifique.
3. **Quelles sont les limites principales des LLMs en matière de génération de texte ?**
   - Hallucinations : production de fausses informations plausibles.
   - Dépendance aux données d'entraînement : manque de mise à jour en temps réel.
   - Coût élevé en ressources pour l'entraînement et l'inférence.
   - Difficulté à comprendre le contexte en profondeur.
4. **Pourquoi le RAG est-il utilisé en complément d'un LLM dans certaines applications ?**
   - Le RAG permet d'améliorer la précision des réponses en récupérant des informations actualisées et externes à partir de bases documentaires.
   - Il réduit les risques d'hallucination en fournissant des faits vérifiables.
5. **Quels sont les avantages et les inconvénients du RAG par rapport au fine-tuning d'un modèle ?**
   - **Avantages** : Pas besoin de réentraîner un modèle, accès à des informations actualisées et précises.
   - **Inconvénients** : La recherche d'informations peut être plus lente, dépendance à la qualité des documents stockés.

Partie 2 : QCM (6 points)

1. **Un modèle RAG est principalement utilisé pour :**
   b) Récupérer des informations externes pour améliorer la réponse
2. **Quel rôle joue une base de données vectorielle comme ChromaDB ?**
   a) Stocker et rechercher des représentations numériques de textes
3. **Lequel des éléments suivants est essentiel pour une API d'IA générative basée sur FastAPI ?**
   a) Un endpoint qui reçoit une requête utilisateur
   c) Une clé API pour interagir avec un service externe
4. **Dans le contexte du prompt engineering, quel type de prompt est le plus efficace pour obtenir une réponse détaillée ?**

b) Un prompt structuré avec des instructions précises
d) Un prompt contenant des exemples et des consignes détaillées

5. **Lequel de ces concepts est utilisé pour structurer une réponse générée par un LLM ?**
   a) Chain of Thought (CoT)
   d) Récupération d'informations avec RAG
6. **Quelles sont les étapes d'une requête RAG ?**
   a) Extraction d'informations pertinentes
   c) Recherche des passages les plus pertinents dans la base vectorielle
   d) Amélioration de la précision grâce à l'embedding des données

Partie 3 : Complétion de phrases (3 points)

1. Un LLM est entraîné en utilisant un grand volume de ***données textuelles*** pour apprendre à générer du texte.
2. Le fine-tuning permet d'adapter un modèle pré-entraîné à un domaine spécifique en l'exposant à des ***exemples*** supplémentaires.
3. Une base de données vectorielle est utilisée dans RAG pour stocker et retrouver des documents sous forme de ***vecteurs***.
4. Le RAG aide à compenser les limites d'un LLM en intégrant des informations ***externes*** dans la génération de texte.
5. Une des principales faiblesses des LLMs est leur tendance à générer des ***hallucinations***, des informations incorrectes qui semblent plausibles.
6. Le Chain of Thought (CoT) permet d'améliorer les réponses des LLMs en encourageant un raisonnement ***explicite***.

Partie 4 : Étude de Cas (6 points)

1. Décrire l'architecture technique du chatbot (2,5 pts)

a) Principaux composants techniques du chatbot :

- Interface utilisateur (site web, application mobile).
- Backend API (développé avec FastAPI).
- Modèle LLM (ex. : GPT, Gemini, Mistral).
- Base de données vectorielle (ex. : ChromaDB pour RAG).

b) Interaction entre les composants :

- L'utilisateur envoie une requête via l'interface.
- L'API interroge le LLM et/ou la base vectorielle en cas d'utilisation de RAG.
- La réponse générée est renvoyée à l'utilisateur après traitement.

c) Avantages de cette architecture :

- Scalabilité : permet d'intégrer des mises à jour de la base documentaire sans réentraîner le modèle.
- Précision améliorée grâce à RAG.

- Facilité d’extension et d’intégration avec d’autres services.

2. Utilisation de RAG pour améliorer la pertinence des réponses (1,5 pts)

a) Pourquoi RAG est utile ?

- Il permet d’enrichir la réponse avec des données actualisées et précises.
- Il réduit les erreurs et les hallucinations du LLM.

b) Fonctionnement des données dans RAG :

- Les documents sont convertis en vecteurs et stockés dans une base de données vectorielle.
- Lorsqu’un utilisateur pose une question, une recherche est effectuée pour récupérer les documents les plus pertinents.
- Le modèle utilise ces documents pour formuler une réponse contextuelle.

c) Exemple concret :

- **Question utilisateur** : "Quels sont les derniers produits ajoutés à votre catalogue ?"
- **Processus** :
    - Le chatbot interroge la base vectorielle.
    - Il récupère les fiches produits les plus récentes.
    - Il génère une réponse en intégrant ces informations.

3. Optimisation des interactions avec le chatbot (2 pts)

a) Utilisation du prompt engineering :

- Concevoir des prompts détaillés pour guider la génération de texte.
- Ajouter des consignes précises pour structurer les réponses (ex. : "Explique étape par étape").
- Utiliser des exemples dans le prompt pour affiner les réponses.

b) Amélioration grâce au Chain of Thought (CoT) :

- CoT encourage le LLM à détailler son raisonnement au lieu de fournir une réponse brute.
- Ex. : Pour une question complexe, le chatbot divise la réponse en sous-étapes logiques avant de conclure.