Examen Type d'IA Générative

Durée : 1h30
Barème : 20 points

Partie 1 : Quiz – Compréhension des fondamentaux (5 points)

Répondez brièvement aux questions suivantes :

1. Quelle est la différence entre l'entraînement d'un LLM et son fine-tuning ? (1 pt)
2. Pourquoi le fine-tuning d'un LLM est-il parfois préférable à l'utilisation d'un modèle pré-entraîné sans modification ? (1 pt)
3. Quelles sont les limites principales des LLMs en matière de génération de texte ? (1 pt)
4. Pourquoi le RAG est-il utilisé en complément d'un LLM dans certaines applications ? (1 pt)
5. Quels sont les avantages et les inconvénients du RAG par rapport au fine-tuning d'un modèle ? (1 pt)

Partie 2 : QCM (6 points)

Cochez la ou les bonnes réponses.

1. Un modèle RAG est principalement utilisé pour : (1 pt)
   - a) Générer du texte sans source externe
   - b) Récupérer des informations externes pour améliorer la réponse
   - c) Remplacer les bases de données relationnelles
   - d) Traduire du texte en plusieurs langues
2. Quel rôle joue une base de données vectorielle comme ChromaDB ? (1 pt)
   - a) Stocker et rechercher des représentations numériques de textes
   - b) Effectuer des calculs mathématiques avancés
   - c) Compiler du code en langage machine
   - d) Indexer des documents pour une recherche rapide
3. Lequel des éléments suivants est essentiel pour une API d'IA générative basée sur FastAPI ? (1 pt)
   - a) Un endpoint qui reçoit une requête utilisateur
   - b) Un modèle ML entraîné localement
   - c) Une clé API pour interagir avec un service externe
   - d) Un algorithme de cryptographie avancé
4. Dans le contexte du prompt engineering, quel type de prompt est le plus efficace pour obtenir une réponse détaillée ? (1 pt)
   - a) Un prompt court et vague
   - b) Un prompt structuré avec des instructions précises
   - c) Un simple mot-clé
   - d) Un prompt contenant des exemples et des consignes détaillées
5. Lequel de ces concepts est utilisé pour structurer une réponse générée par un LLM ? (1 pt)

- a) Chain of Thought (CoT)
- b) Latent Diffusion Model (LDM)
- c) Fourier Transform
- d) Récupération d'informations avec RAG

6. Quelles sont les étapes d'une requête RAG ? (1 pt)
- a) Extraction d'informations pertinentes
- b) Génération de texte par un LLM sans consultation externe
- c) Recherche des passages les plus pertinents dans la base vectorielle
- d) Amélioration de la précision grâce à l'embedding des données

Partie 3 : Complétion de phrases (3 points)

Complétez les phrases suivantes en choisissant les termes les plus appropriés.

1. Un LLM est entraîné en utilisant un grand volume de _____ pour apprendre à générer du texte. (0,5 pt)
2. Le fine-tuning permet d'adapter un modèle pré-entraîné à un domaine spécifique en l'exposant à des _____ supplémentaires. (0,5 pt)
3. Une base de données vectorielle est utilisée dans RAG pour stocker et retrouver des documents sous forme de _____. (0,5 pt)
4. Le RAG aide à compenser les limites d'un LLM en intégrant des informations _____ dans la génération de texte. (0,5 pt)
5. Une des principales faiblesses des LLMs est leur tendance à générer des _____, des informations incorrectes qui semblent plausibles. (0,5 pt)
6. Le Chain of Thought (CoT) permet d'améliorer les réponses des LLMs en encourageant un raisonnement _____. (0,5 pt)

Partie 4 : Étude de Cas (6 points)

Votre entreprise veut intégrer un chatbot intelligent pour répondre aux questions des clients sur ses produits. Vous devez proposer une solution basée sur ce que vous avez appris en IA générative.

1. Décrire l'architecture technique du chatbot (2,5 pts)

Dans votre réponse, précisez :

a) Quels sont les principaux composants techniques du chatbot?
b) Comment ces composants interagissent-ils entre eux ?
c) Pourquoi avez-vous choisi cette architecture et quels avantages offre-t-elle ?

2. Utilisation de RAG pour améliorer la pertinence des réponses (1,5 pts)

Expliquez :

a) Pourquoi RAG est utile pour améliorer les réponses du chatbot ?
b) Comment les données sont stockées, récupérées et utilisées pour enrichir les réponses ?
c) Donnez un exemple concret de question d'un utilisateur et expliquez comment le chatbot y répondrait avec RAG.

3. Optimisation des interactions avec le chatbot (2 pts)

Décrivez :

a) Comment le prompt engineering peut aider à générer des réponses plus naturelles et adaptées aux questions des utilisateurs ?
b) En quoi le Chain of Thought (CoT) permet d'améliorer la qualité des réponses du chatbot en lui faisant détailler son raisonnement ?