

Découverte du framework Langchain

Initiation et introduction aux LLMS

Haythem GHAZOUANI







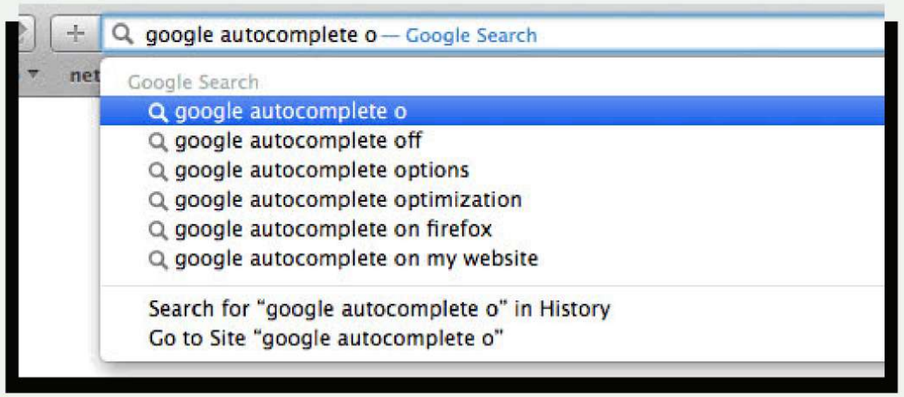
Plan



1. IA ? NLP ? Transformer ?
2. C’est quoi un LLMs ?
3. C’est quoi Langchain?
4. Langchain, concepts
5. Petite découverte de Hugging Face
6. Applications réels

NLP

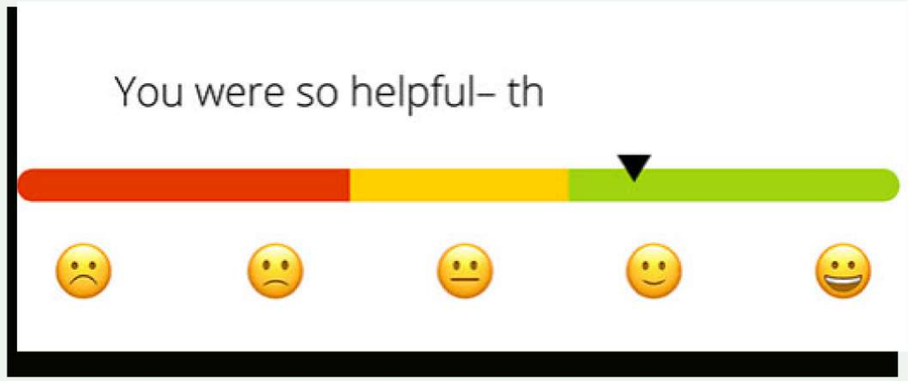
Branche de l’IA - compréhension, l'interprétation et la manipulation du langage humain



Auto-Completion Google

Google translate





Analyse de sentiments

Evolution du NLP

1988

RNN

1997

LSTM

2017

Transformers avec article Populaire "Attention is all you need" de Google Brain

2018

BERT de GOOGLE (Bidirectional Encoder Representations from Transformers)

2018

GPT dans l'article "Improving Language Under-standing by Generative Pre-Training"

2019

GPT-2

2020

GPT-3

2021

GPT-3.5

2022

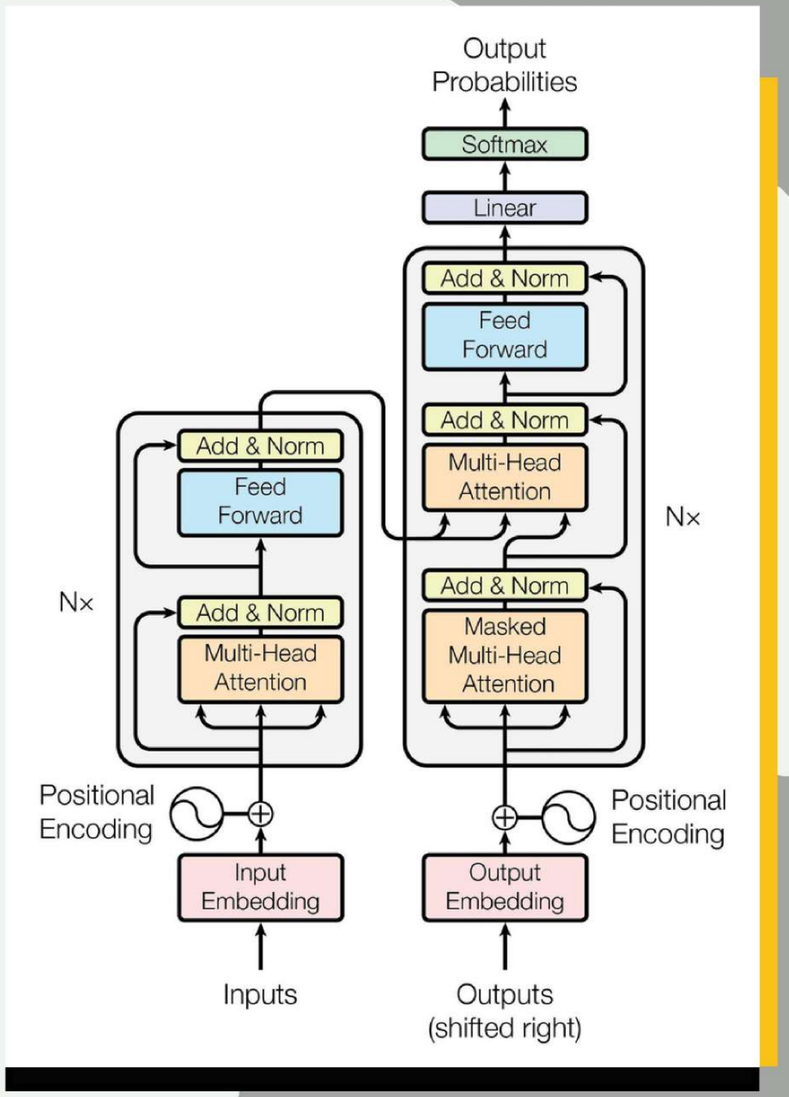
GhatGPT, InstructGPT, PaLM

LLaMA, Falcon, GPT 4, PaLM 2, BARD



Focus sur les Transformers

Les Transformers, architecture, introduits par **Google**, permettant un traitement **parallèle** du langage et une compréhension **contextuelle** améliorée.



C’est quoi un LLMs ?

un modèle d’apprentissage en profondeur (deep learning) basé sur l'architecture des Transformers qui comprend et génère du texte de manière humaine.



Génération de texte 1

Produire des articles, des histoires, et d'autres formes de contenu écrit de manière cohérente et créative.

Traduction automatique 2

Traduire des textes entre différentes langues en conservant le sens et le contexte.

Résumé automatique

Condenser de longs documents en résumés concis sans perdre les informations essentielles

Réponses aux questions

Fournir des réponses précises à des questions posées en langage naturel.

Exemple de LLMS

GPT 3

un modèle géant avec 175 milliards de paramètres, célèbre pour sa capacité à générer du texte

BERT



Developpé en 2018 par Google, BERT est un des premier LLMS avec plusieurs tâches compréhension de texte, question réponse

LLAMA



Proposé par Meta, LLaMA se distingue par sa performance et son accessibilité,

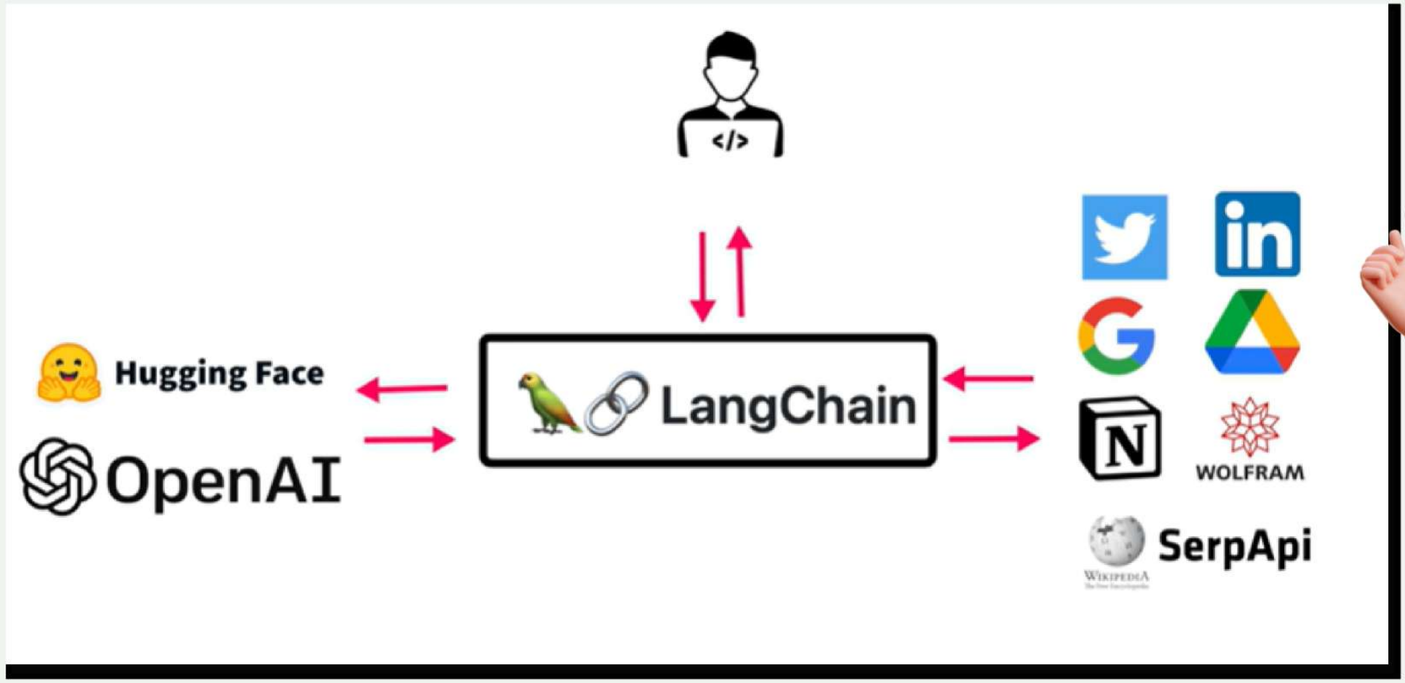
Mistral

La pépite française de l'IA générative Mistral AI dévoile un tout nouveau grand modèle de langage (LLM) baptisé Mistral Large.



C’est quoi un Langchain

Un framework conçu pour développer des applications alimentées par des **modèles de langage**, en facilitant leur intégration dans **diverses applications**.





Pourquoi Langchain?

Flexibilité

1

Simplifie l'intégration de grands modèles de langage dans leurs applications que ce soit OpenAI ou ceux HuggingFace

Automatisation

2

orchestrer une séquence d'actions en utilisant un modèle de langage :



Les services tiers

3

Les développeurs bénéficient d'un accès à des services tiers exhaustifs, tels que les API de Google, et des intégrations avec des plateformes sociales comme LinkedIn et

La communauté

4

Langchain Hub est une ressource inestimable où la communauté peut partager et s'inspirer d'agents, de codes et de prompts déjà créés.

IceBreaker

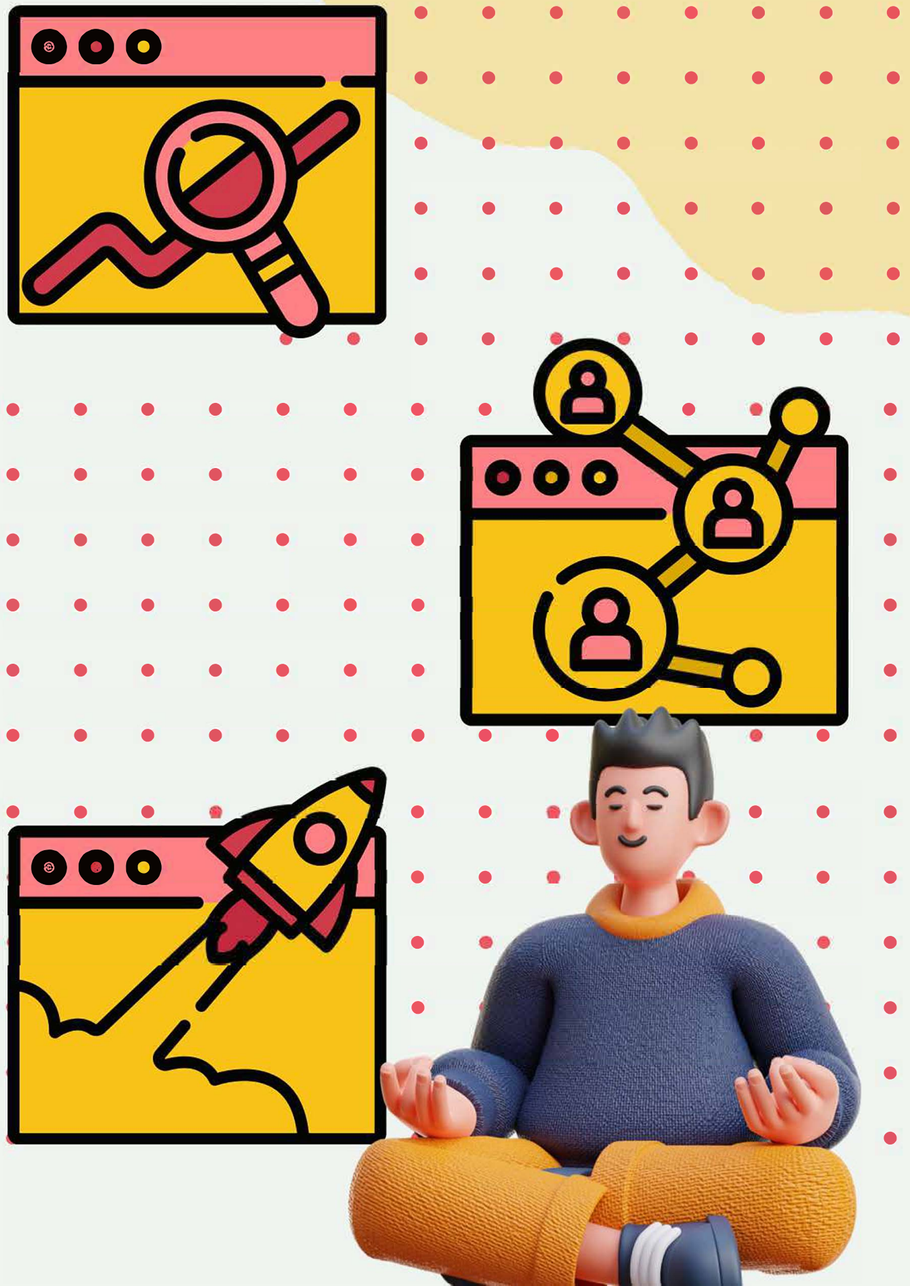
Nous utiliserons Langchain pour développer une application qui va,

- **Recevoir une requète (Question) sur les articles disponibles dans une boutiques et/ou mode homme/ femme 2025**
- Rechercher dans les données de la boutique
- Générer une réponse sur les articles disponibles avec possibilité de conseils personalisés



Concepts

- LLMChain
- ChromaDB
- Agents
- Document Loader
- RAG



Code de base

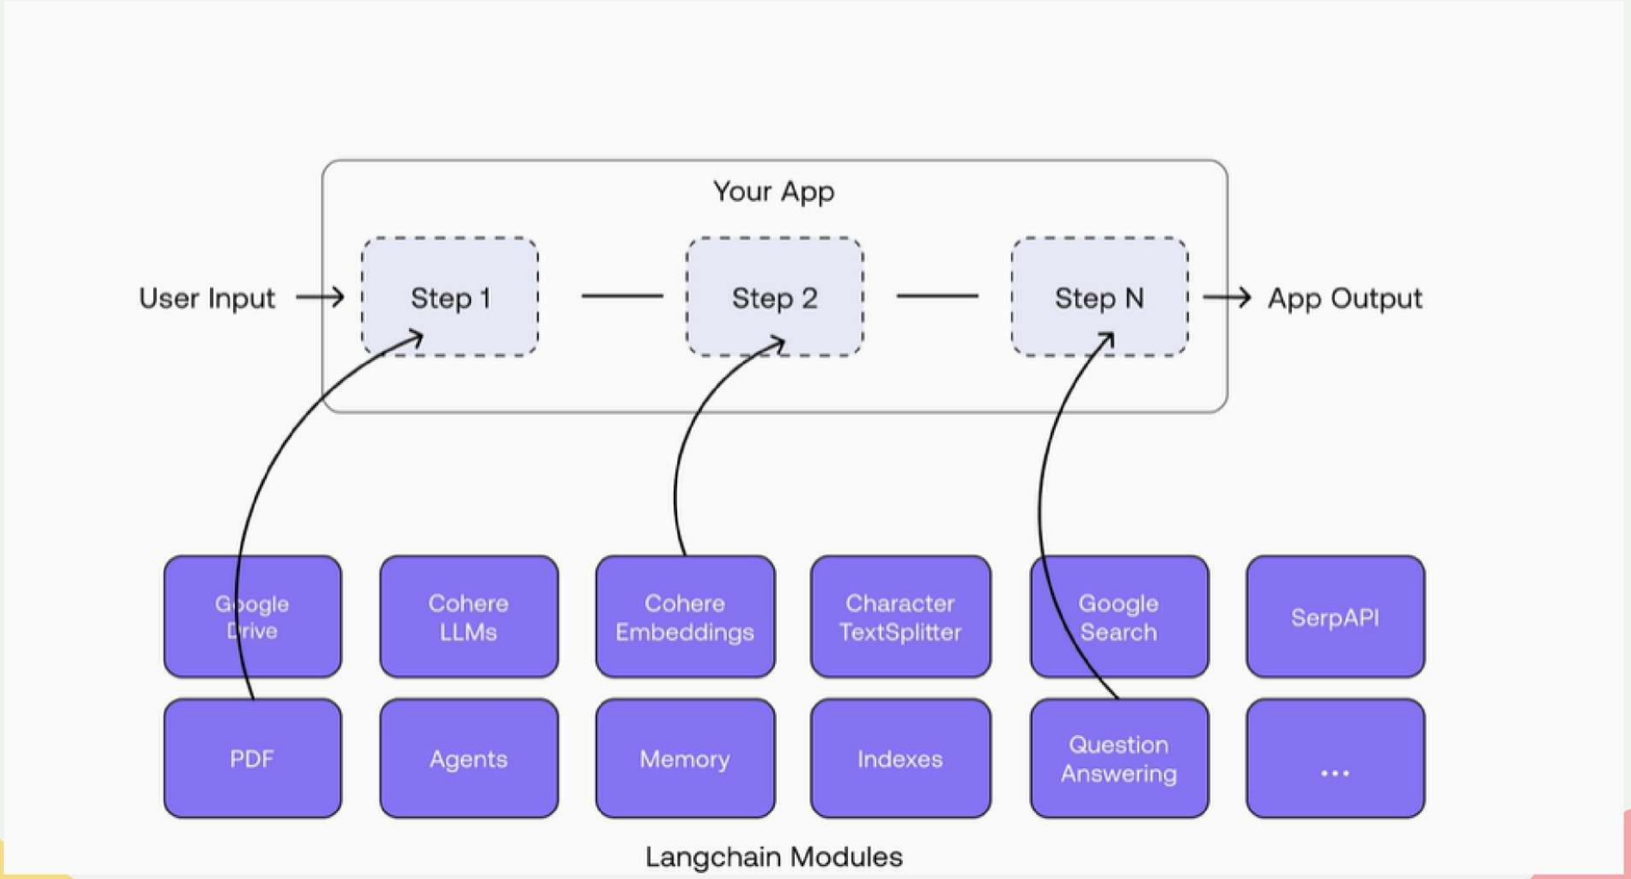
```python
# Initialisation du modèle Groq
groq_llm = ChatGroq()

# Création du prompt pour Groq
prompt_template = "Répondez à la question suivante en vous basant sur le contexte fourni: {context}"

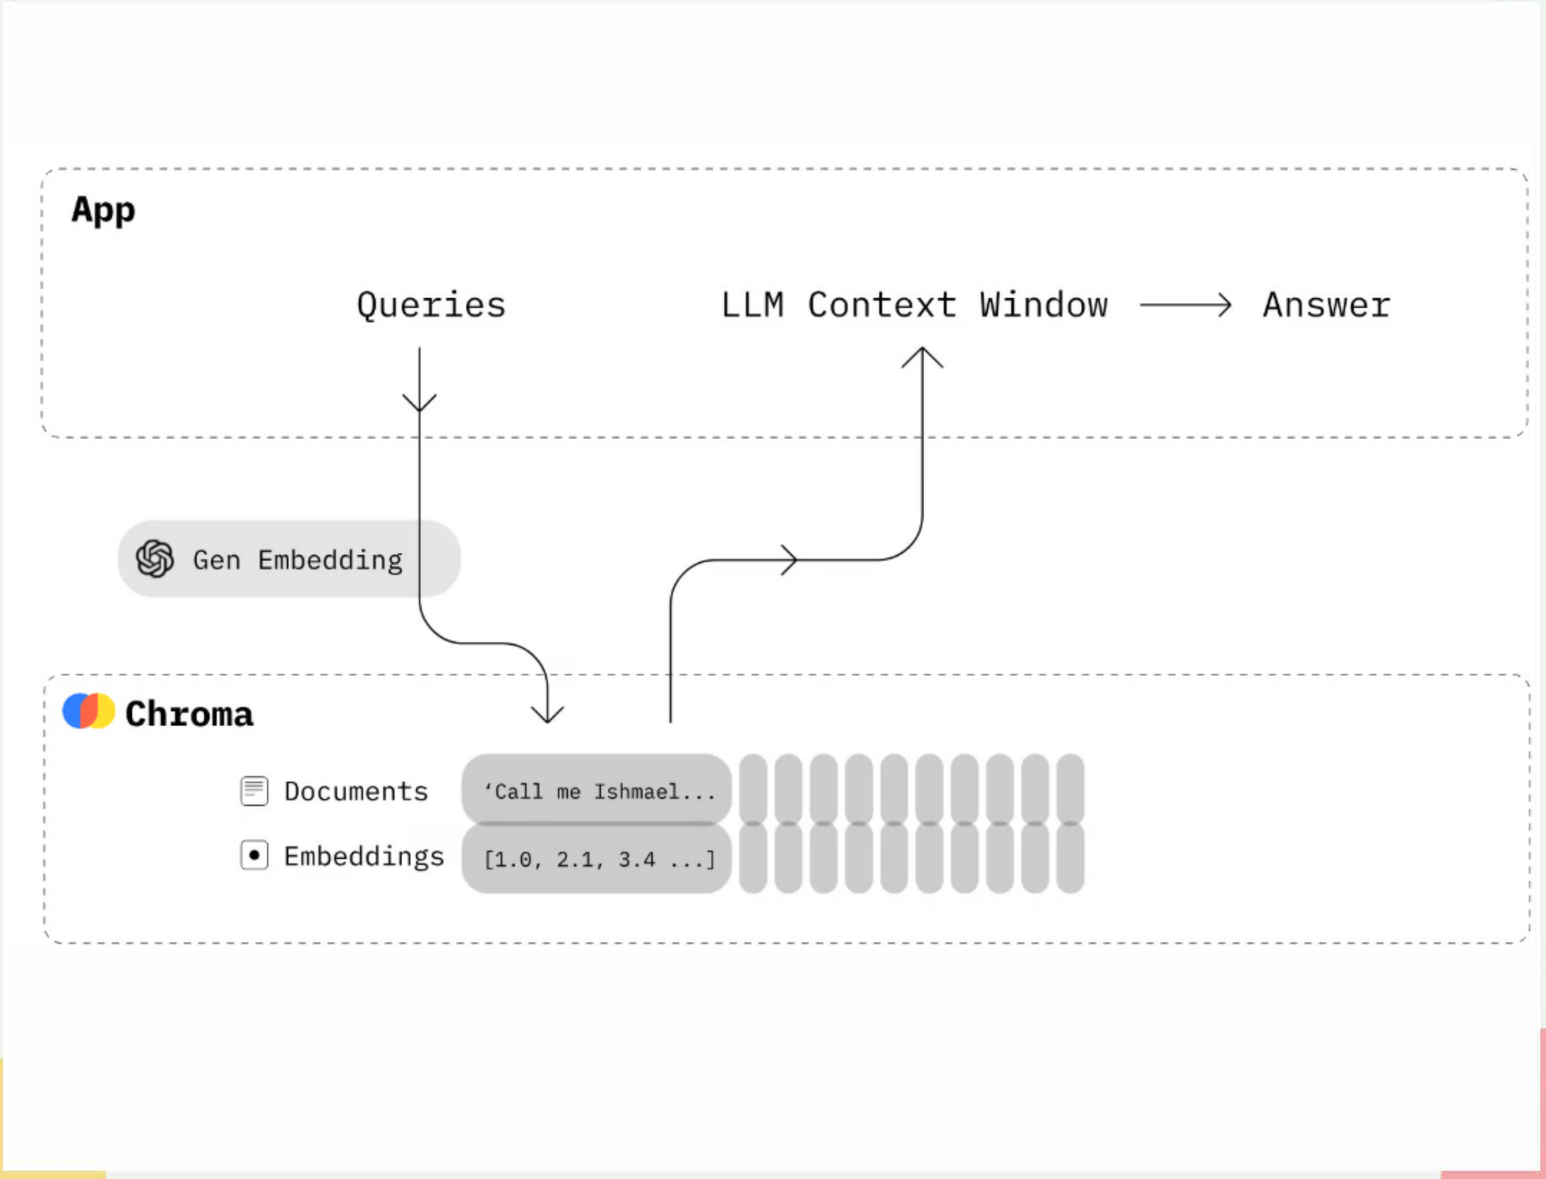
# Définition de la chaîne QA avec le retriever
qa_chain = RetrievalQA.from_chain_type(
    llm=groq_llm,
    chain_type="stuff",
    retriever=vectorstore.as_retriever(),
    return_source_documents=True
)
```

LLMCHAIN

Permet de combiner **plusieurs composants** ensemble et créer une **application cohérente et complexe.**

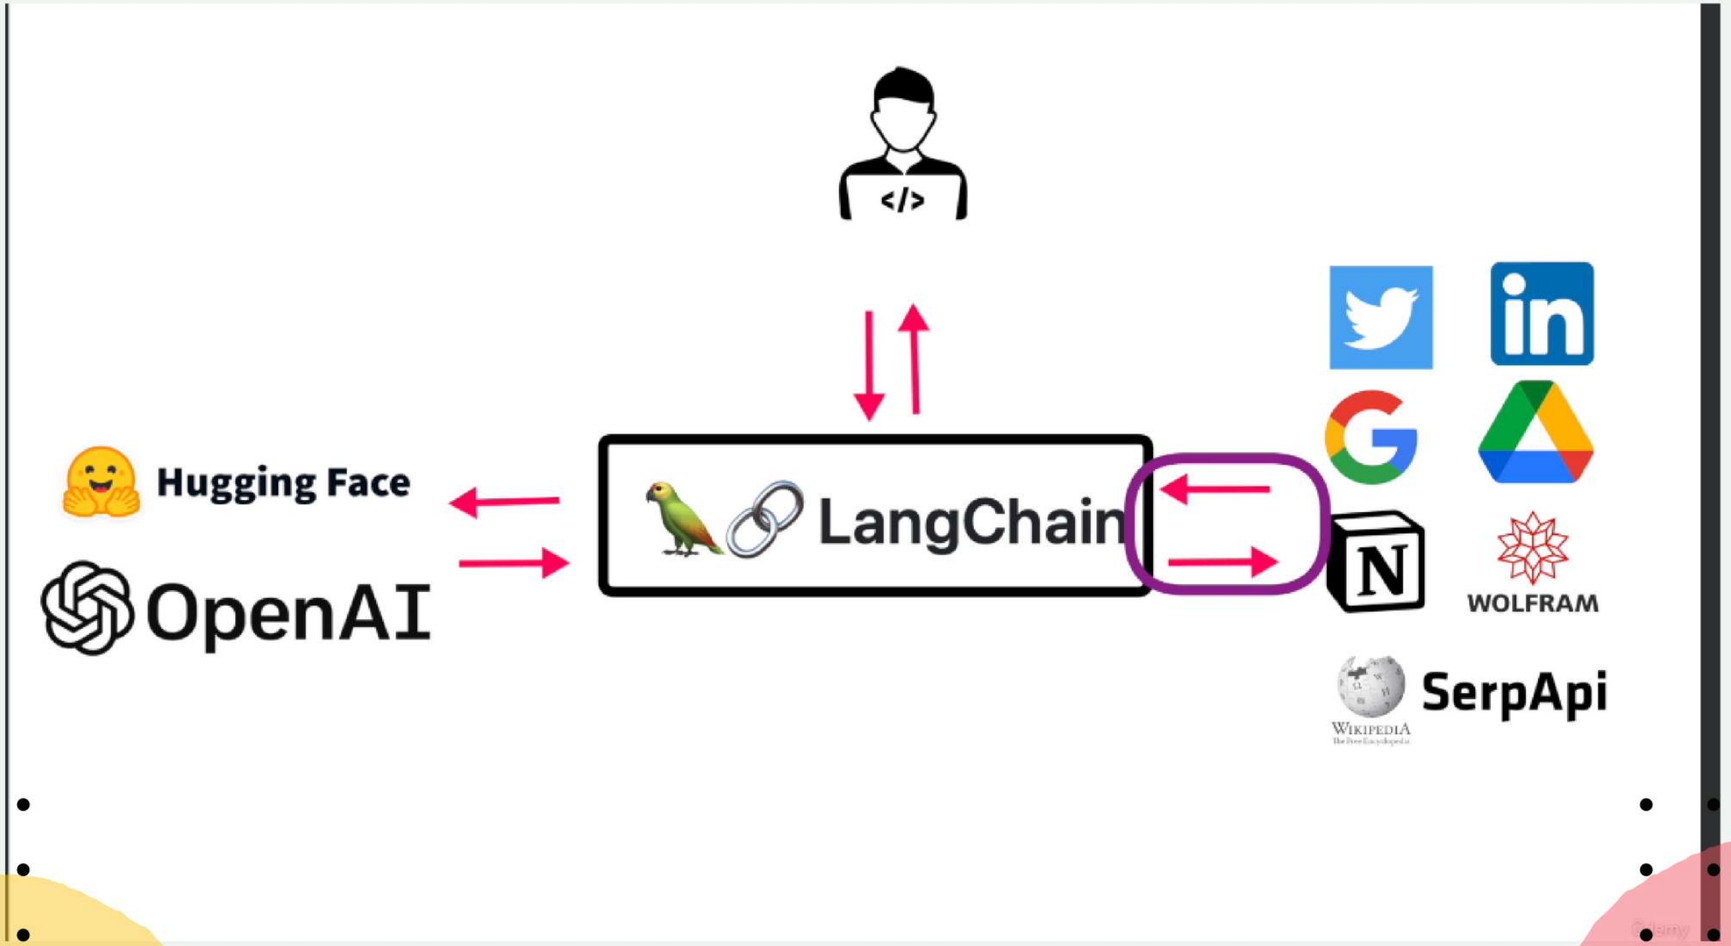


ChromaDB

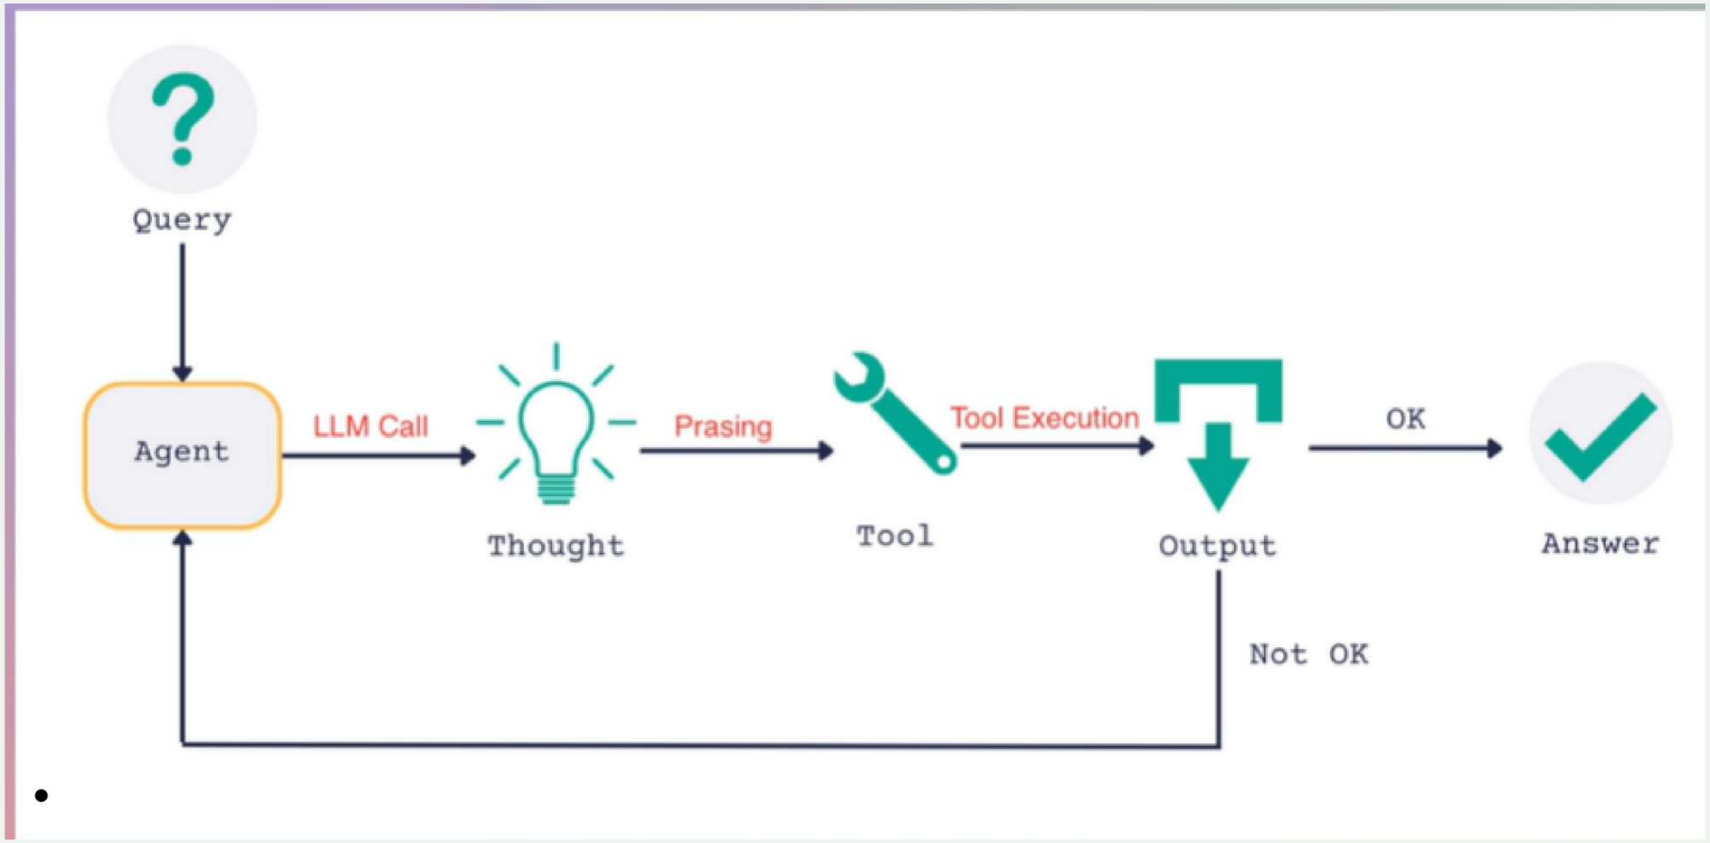

App
Queries
LLM Context Window
Answer
Gen Embedding
Chroma
Documents
'Call me Ishmael...
Embeddings
[1.0, 2.1, 3.4 ...]

Agents

Agent est comme un robot qui effectue des actions en votre nom en exploitant les **outils** pour répondre à une tâche.

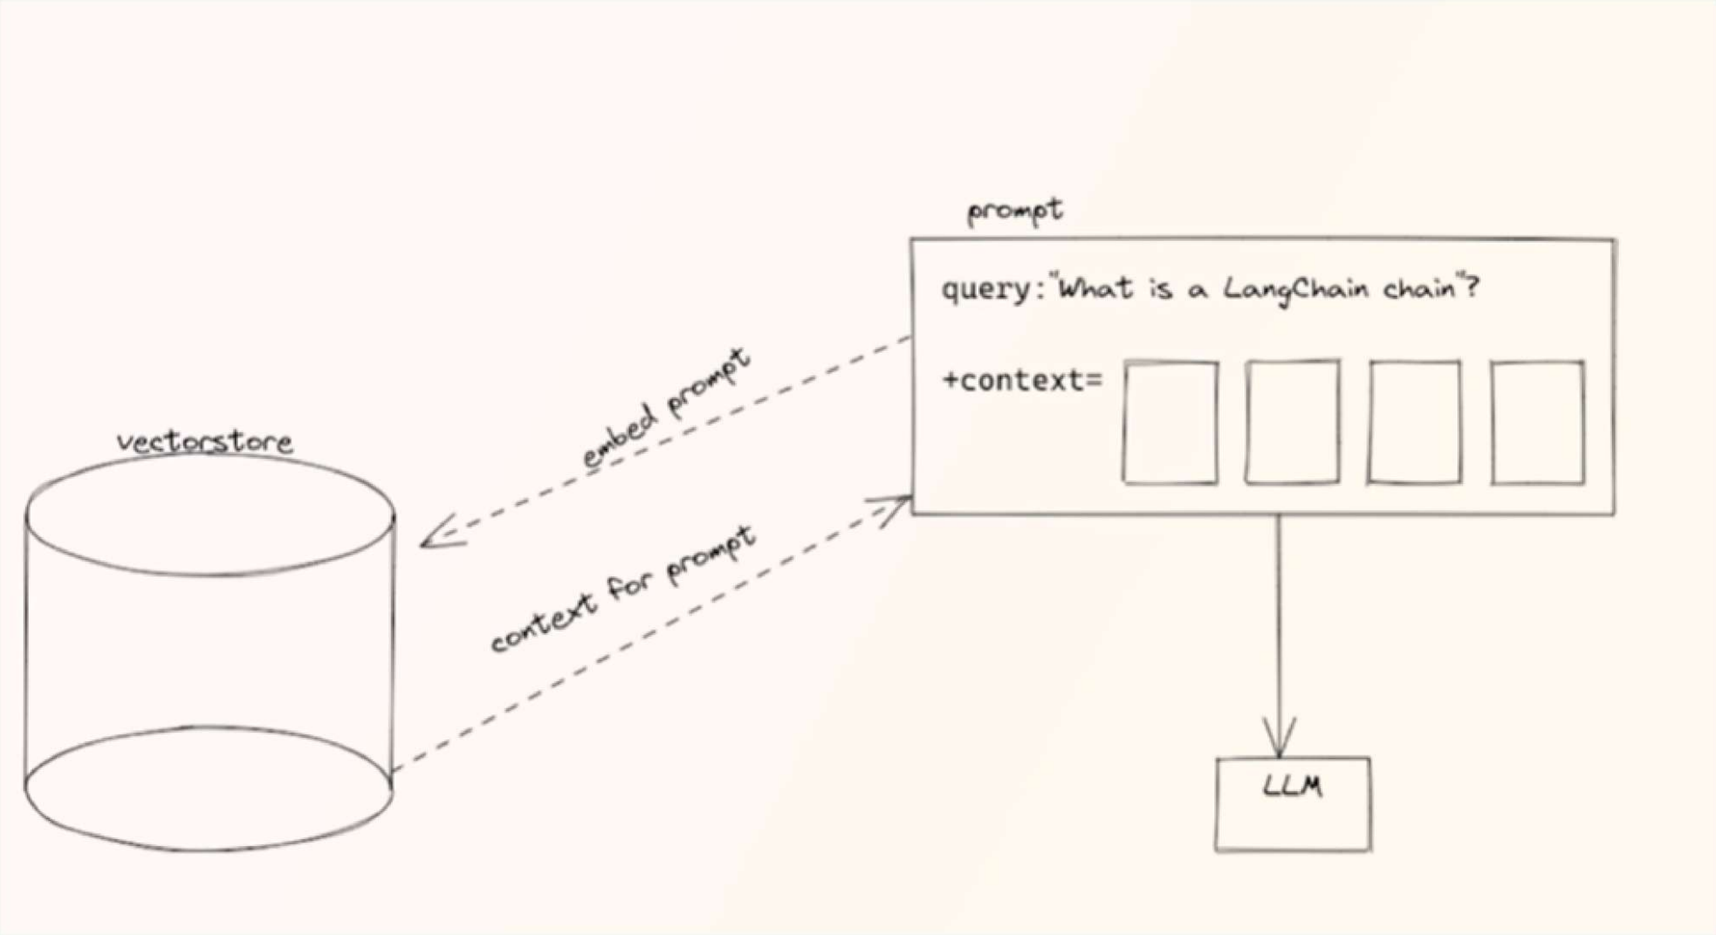


Agents


Query
Agent
LLM Call
Thought
Prasing
Tool
Tool Execution
Output
OK
Answer
Not OK

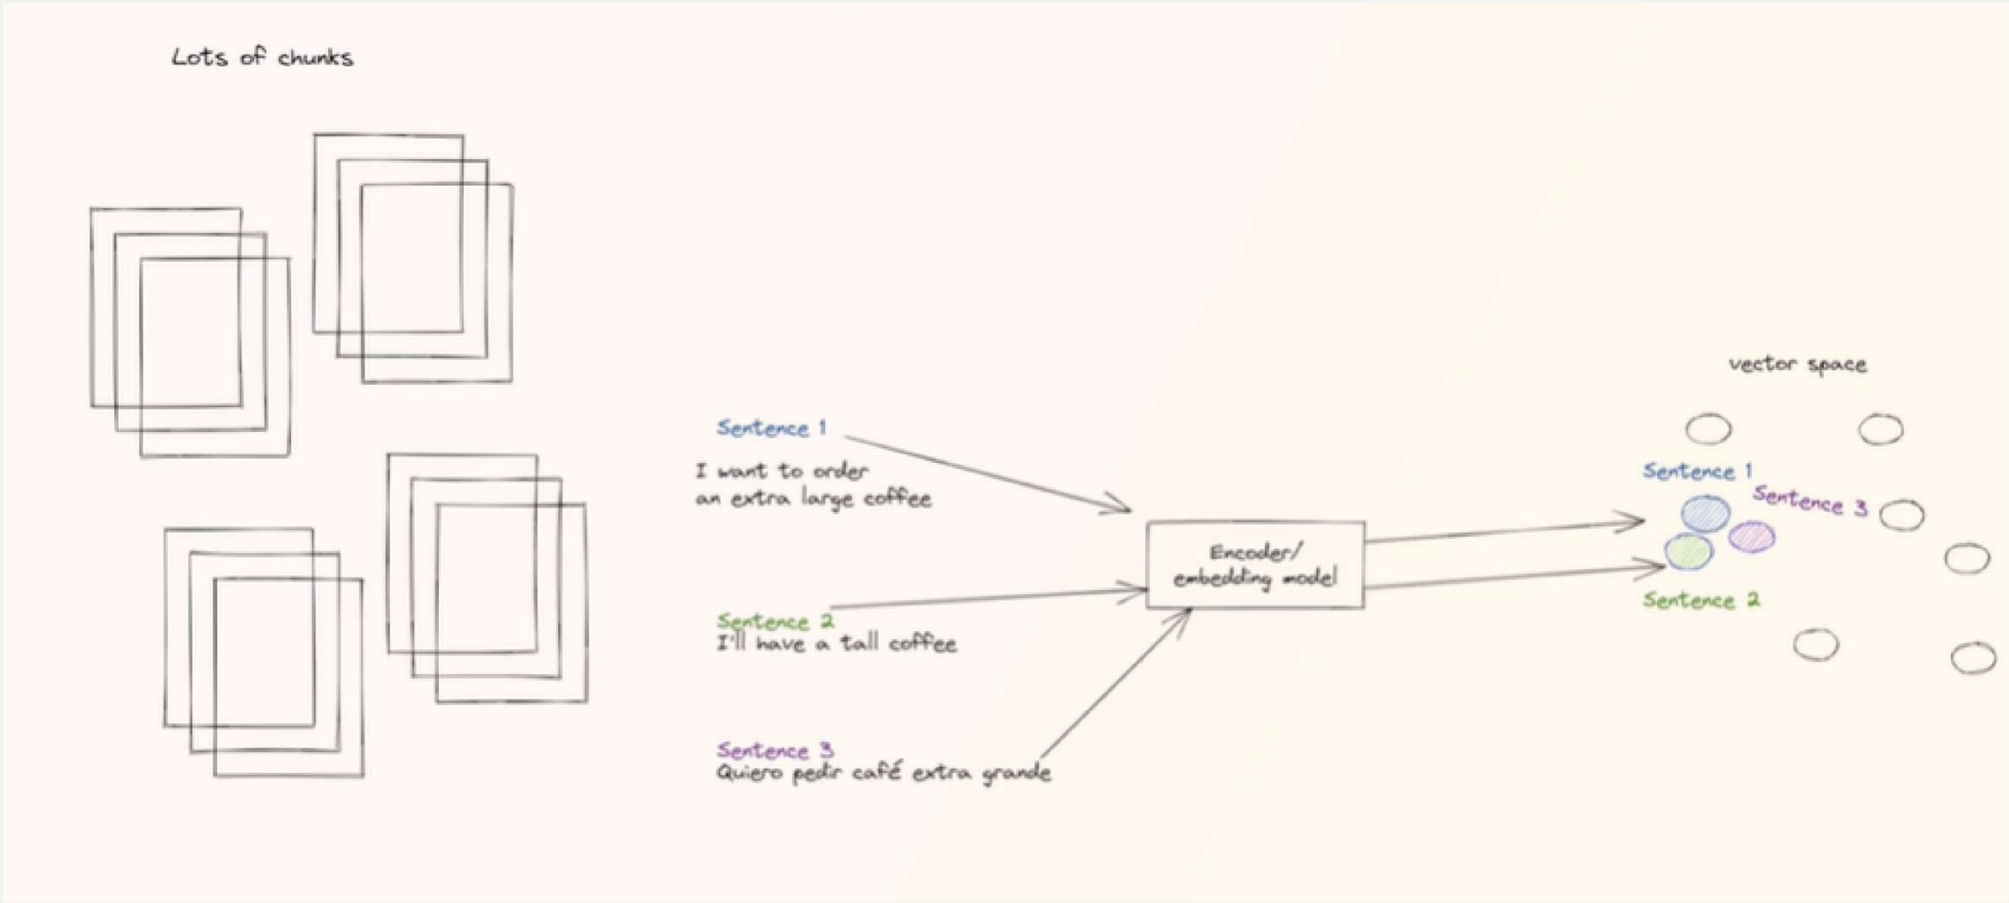


RAG


prompt
query: "What is a LangChain chain"?
+context=
vectorstore
embed prompt
context for prompt
LLM

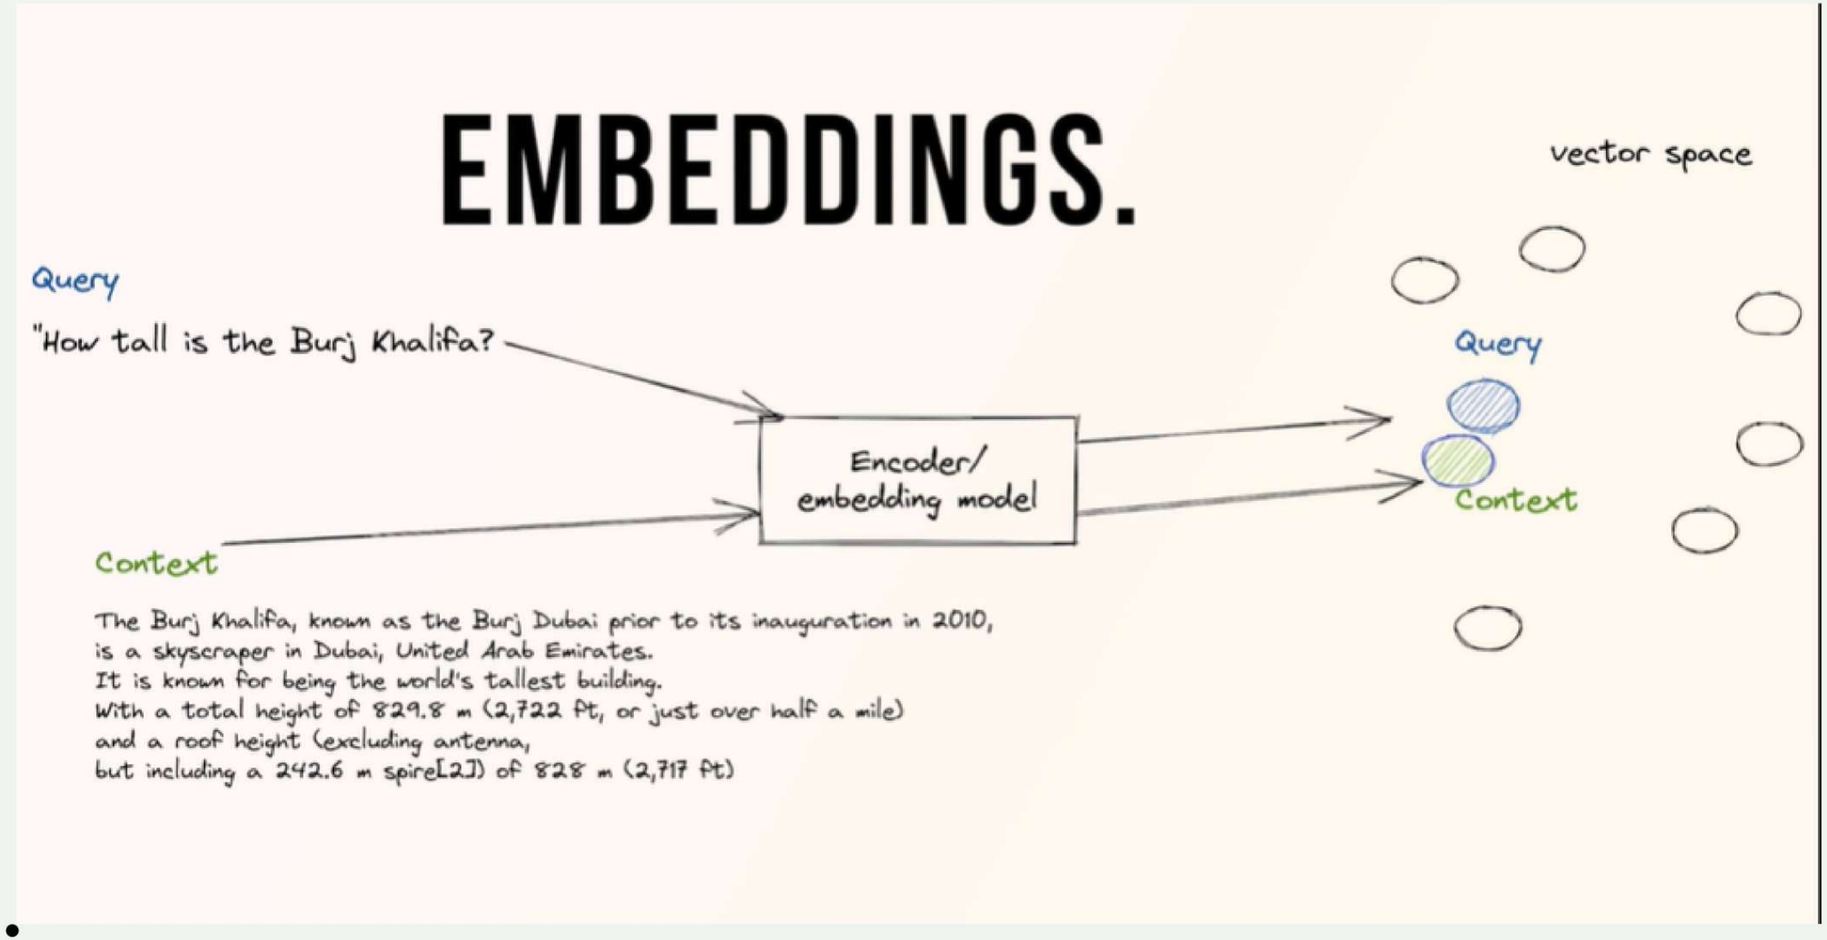


RAG


Lots of chunks
Sentence 1
I want to order
an extra large coffee
Sentence 2
I'll have a tall coffee
Sentence 3
Quiero pedir café extra grande
Encoder/
embedding model
vector space
Sentence 1
Sentence 3
Sentence 2



RAG


EMBEDDINGS.
vector space
Query
"How tall is the Burj Khalifa?
Encoder/
embedding model
Context
Query
Context
The Burj Khalifa, known as the Burj Dubai prior to its inauguration in 2010,
is a skyscraper in Dubai, United Arab Emirates.
It is known for being the world's tallest building.
With a total height of 829.8 m (2,722 ft, or just over half a mile)
and a roof height (excluding antenna,
but including a 242.6 m spire[2]) of 828 m (2,717 ft)




DEMO

Thank you!

Haythem GHAZOUANI

+229 97 68 92 45

https://github.com/princegedeon

