Introduction à OLLAMA

DÉPLOYER UN LLM EN LOCAL

HAYTHEM GHAZOUANI

Introduction à Ollama

- Ollama est un outil permettant d'exécuter des LLMs en local.
- Il optimise l'exécution et facilite l'intégration via API.
- Fonctionne sous Windows, Mac et Linux.
- Compatible avec plusieurs modèles comme Mistral, Llama 2, Gemma.

Installation d'Ollama

1. Télécharger depuis https://ollama.com
2. Installer l’exécutable sous Windows ou via Terminal sous Linux/Mac
3. Vérifier avec : ollama --version

Téléchargement et exécution d'un modèle

1. Télécharger un modèle : ollama pull mistral
2. Lancer le modèle : ollama run mistral
3. Utiliser en ligne de commande ou via API

Utilisation d'Ollama via Python

1. Installer le package Python : pip install ollama

2. Exemple de script :

```
import ollama

response = ollama.chat(model='mistral', messages=[{'role': 'user', 'content': 'Bonjour'}])

print(response['message']['content'])
```

Modèles légers recommandés

- TinyLlama (3B)
- Gemma (2B, 7B)
- Mistral (7B)
- Phi (2.7B)
- Llama2-7B

Personnalisation avec Modelfile

1. Créer un fichier `Modelfile` :

```
FROM mistral
SYSTEM 'Tu es un assistant en mathématiques.'
```

2. Construire le modèle : ollama create monmodele -f Modelfile
3. Exécuter : ollama run monmodele

Limitations d'Ollama

- Pas de fine-tuning complet (seulement adaptation via Modelfile)
- Modèles gourmands en ressources
- Nécessite du stockage pour les modèles lourds

Exercices pratiques

1. Installer Ollama et télécharger un modèle
2. Exécuter un modèle en ligne de commande
3. Tester l'API avec Python
4. Créer un modèle personnalisé avec Modelfile