Introduction à l'IA Générative

Concepts fondamentaux · LLMs · Chatbots · Applications

Résumé de cours — 1ère Année Cycle Ingénieur

1 Qu'est-ce que l'IA Générative ?

L'IA générative est une branche de l'intelligence artificielle capable de **créer du contenu original** (texte, images, musique, code, vidéo…) en apprenant les structures sous-jacentes de grandes quantités de données. Contrairement à l'IA *discriminative* (qui classifie), elle **génère** du nouveau contenu.

Avant 2017

- ■ Réseaux de neurones récurrents (RNN)
- ■ GAN — Generative Adversarial Networks (2014)
- ■ Applications et résultats limités

2017 → Aujourd'hui

- ■ Architecture **Transformer** (2017) — tournant majeur
- ■ GPT, BERT, T5, Claude, Gemini…
- ■ Diffusion models : DALL-E, Stable Diffusion

2 Les Grands Modèles de Langage (LLMs)

LLM = Large Language Model · Modèles d'IA entraînés sur d'énormes corpus de texte pour comprendre et générer du langage humain. Ils contiennent des **milliards de paramètres** et utilisent l'architecture Transformer.

Étape	Nom	Description
1	**Tokenisation**	Découpage du texte en unités (tokens : mots ou parties de mots)
2	**Embedding**	Conversion de chaque token en vecteur numérique représentant son sens
3	**Traitement**	Analyse des relations entre tokens via le mécanisme d'**attention**
4	**Prédiction**	Génération du token suivant le plus probable (processus autorégressif)
5	**Décodage**	Conversion de la séquence de tokens en texte lisible final

Pré-entraînement

Apprentissage non supervisé sur des trillions de tokens (Internet, livres, code…).

Objectif : prédire le mot suivant.

Fine-tuning / RLHF

Adaptation à des tâches spécifiques via des données étiquetées.

RLHF = retour humain pour aligner le comportement du modèle.

3 Les Chatbots basés sur les LLMs

Critère	Chatbot traditionnel	Chatbot LLM (ex: ChatGPT, Claude)
Base	Règles prédéfinies	Modèle de langage profond
Réponses	Scriptées, fixes	Générées dynamiquement
Flexibilité	Très limitée	Adaptatif, multi-sujets
Compréhension	Mots-clés seulement	Contextuelle et nuancée
Exemples	Bots FAQ, IVR	ChatGPT, Claude, Gemini

4 Applications & Concepts Clés

Texte & Langage

- Rédaction, résumé, traduction
- Documentation technique
- Assistance juridique/médicale

Images & Design

- DALL-E, Midjourney, Stable Diffusion
- Design graphique automatisé
- Génération d'illustrations

Code & Dev

- GitHub Copilot, débogage
- Génération de fonctions
- Tests automatisés

Autres domaines

- Musique (MusicLM), Vidéo (Sora)
- Éducation : tuteurs IA
- Santé : aide au diagnostic

5 Glossaire des Concepts Essentiels

Terme	Définition
Token	Unité de base traitée par un LLM : mot, partie de mot, ou caractère.
Prompt	Instruction ou texte fourni au modèle pour guider sa réponse.
Température	Paramètre (0–2) contrôlant la créativité : 0 = déterministe, 2 = très créatif.
Hallucination	Génération d'informations fausses mais plausibles — limite critique des LLMs.
Few-shot	Apprentissage à partir de quelques exemples fournis directement dans le prompt.
Fine-tuning	Ré-entraînement ciblé d'un modèle pré-entraîné sur des données spécifiques.
Embedding	Représentation vectorielle d'un mot/phrase capturant son sens sémantique.
RLHF	Reinforcement Learning from Human Feedback : alignement via retour humain.

6 Prompt Engineering — L'art de bien interroger un LLM

Bonnes pratiques

- ■ Soyez **clair et précis** sur ce que vous attendez
- ■ Donnez du **contexte** suffisant
- ■ Utilisez des **exemples** (few-shot)
- ■ Précisez le **format de sortie** souhaité
- ■ **Décomposez** les tâches complexes

Exemple concret

Prompt faible :

"Parle-moi de l'IA."

Prompt efficace :

"Explique l'IA générative en 3 points simples pour un étudiant ingénieur débutant, avec une analogie concrète pour chaque point."

7 Limites Techniques et Défis Éthiques

Limites Techniques	Défis Éthiques & Sociaux
■ **Hallucinations** : génère du faux plausible ■ Fenêtre de contexte limitée (nb de tokens) ■ Connaissances figées à la date d'entraînement ■ Biais dans les données d'entraînement ■ Coûts computationnels et énergétiques énormes	■ Désinformation et **deep fakes** ■ Propriété intellectuelle et droits d'auteur ■ Impact sur l'emploi et les métiers ■ Confidentialité des données personnelles ■ Concentration du pouvoir technologique

■■ *Point critique : Les LLMs ne comprennent pas réellement le contenu — ils génèrent du texte **statistiquement probable** basé sur leur entraînement. Il faut toujours vérifier les informations importantes qu'ils produisent.*

8 Points Clés à Retenir

1. L'IA générative crée du contenu original en apprenant les patterns des données d'entraînement.
2. Les LLMs fonctionnent par prédiction itérative du token suivant grâce à l'architecture Transformer.
3. Les chatbots modernes (ChatGPT, Claude, Gemini) sont des interfaces conversationnelles sur des LLMs.
4. Le Prompt Engineering est une compétence clé : la qualité de la réponse dépend de la qualité de la demande.
5. Les LLMs ont des limites réelles : hallucinations, biais, données non à jour — utilisation critique indispensable.